CHINA LINUX KERNEL
中国Linux内核开发者大会

vivo

EXT4块分配可扩展性优化

李保坤
华为操作系统部

背景

众核高密场景通过 will-it-scale 测试内核可扩展性，发现 ext4 在 fallocate2 用例（8k追加fallocate到1M，然后truncate 为 0）中 IOPS 随容器数量增加下滑严重。火焰图中可以观察到严重的锁竞争。

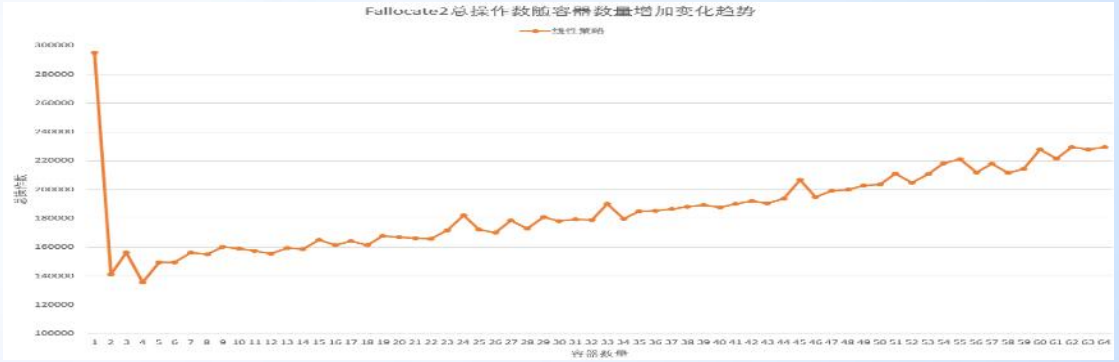

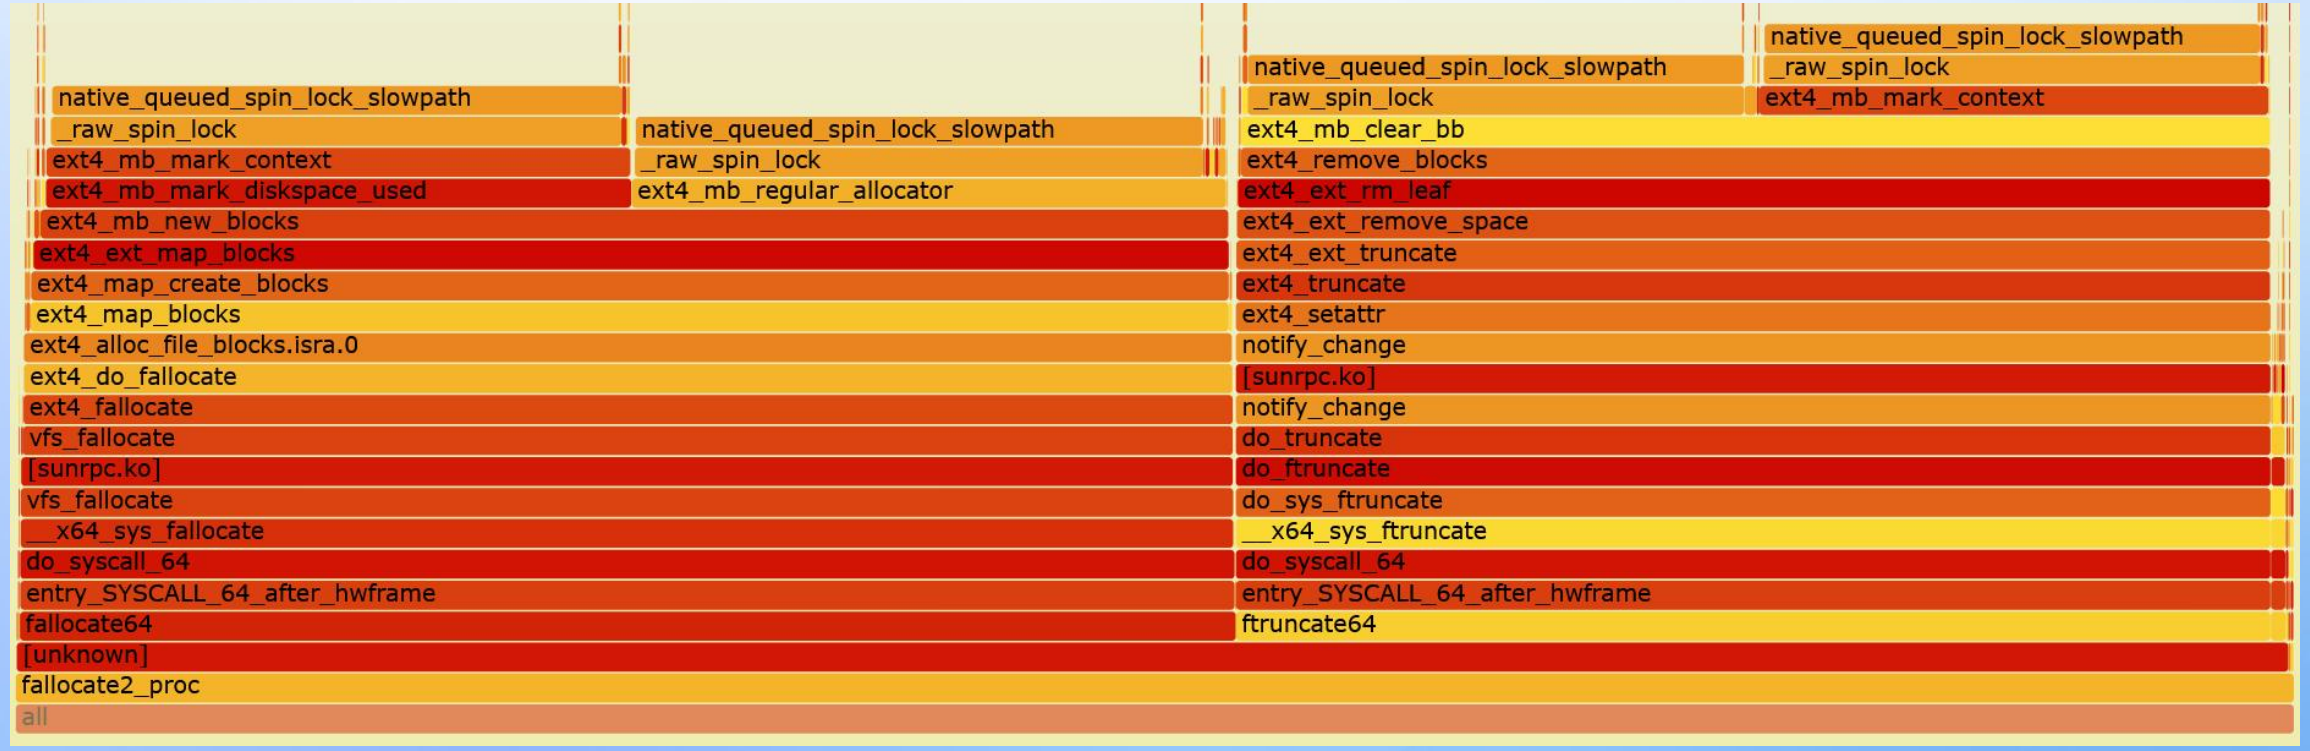

知识背景

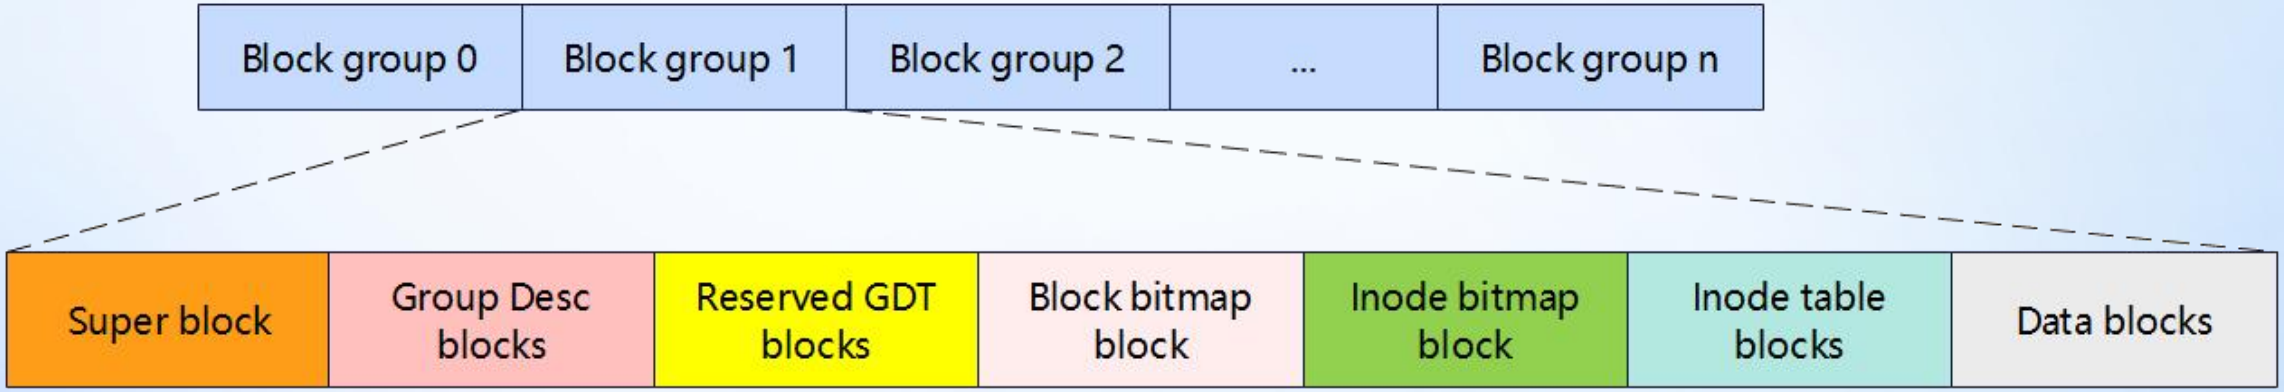

- EXT4 文件系统把磁盘分为多个块组
- Inode 和 空闲块都是从块组中分配
- 块分配开始目标为 inode 所在组或已有extent所在组
- 目标分配失败则遍历所有块组，直到找到空闲块

块组线性遍历

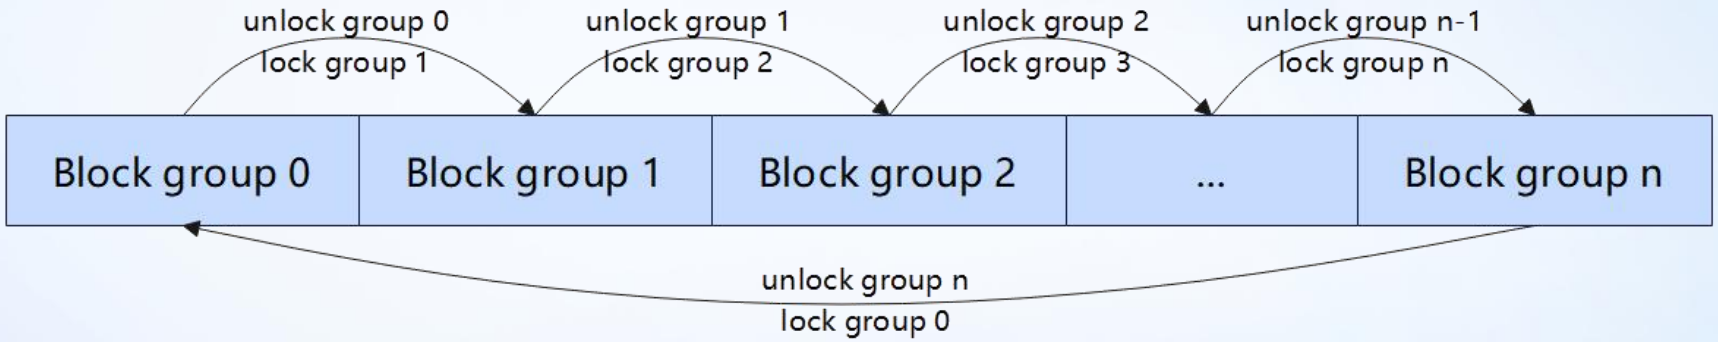

问题：

多个进程分配块遍历组时，先持锁的进程会阻塞后续进程。多个块组在同一个group中分配/释放块导致严重的 group 锁竞争。

优化：

遍历 group 时都是非目标块组，不是一定要在某个 group 中分配块，引入 trylock 机制来跳过繁忙组，这也可以避免一些不同进程后续块释放时的 group 锁竞争。

stream allocation

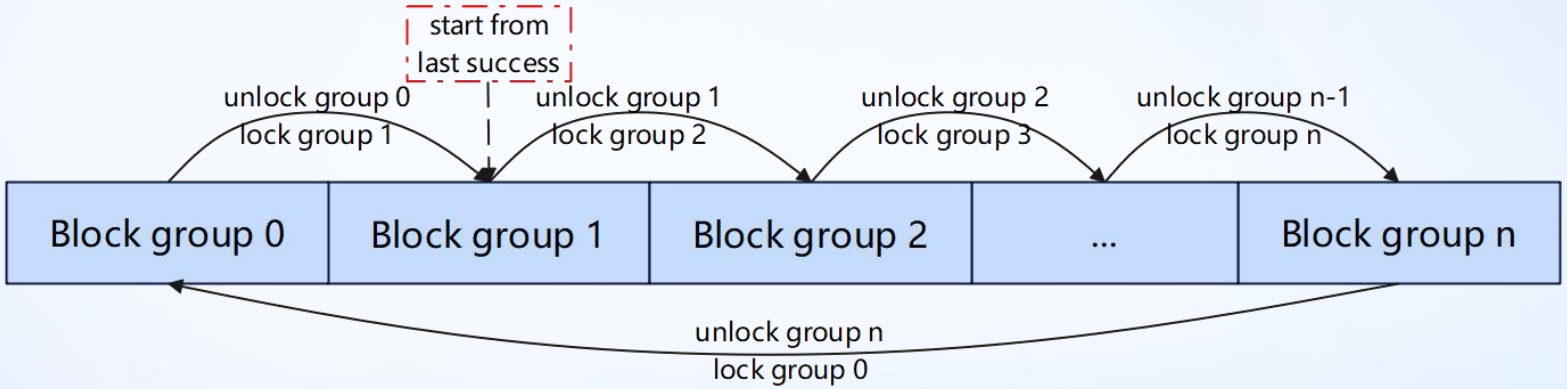

问题：

该特性在块分配前持有 s_md_lock 获取上次块分配成功的位置，设置为块组遍历的起始位置，并在块分配后持有 s_md_lock 更新该全局目标。当多个进程分配块时，单一全局目标导致 s_md_lock 竞争严重.

优化：

- 由于该全局目标只是 hint，因此删除 s_md_lock 改为 READ_ONCE/WRITE_ONCE.
- 将全局目标拆分为多个，按照 inode 号 hash 分桶，避免无效遍历。

mb_optimize_scan

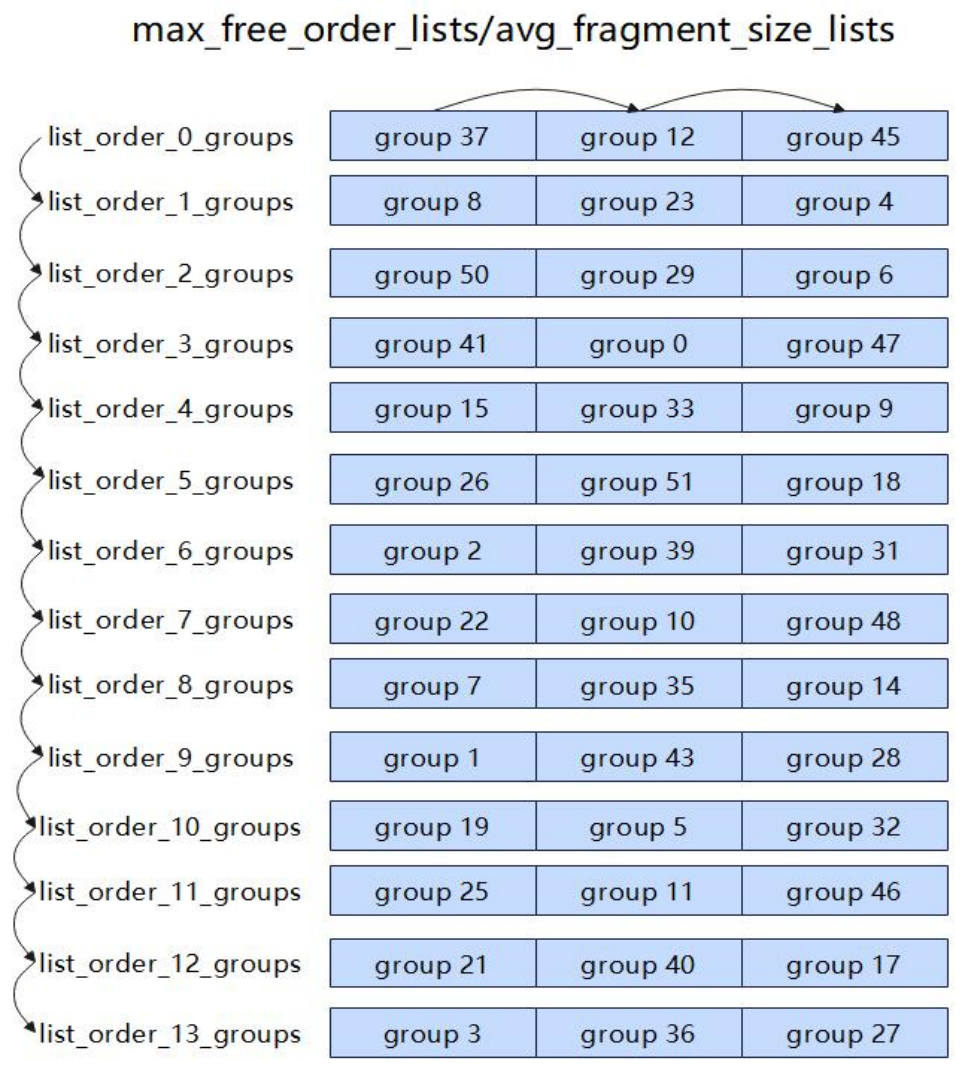


```
// 遍历次数不超过group的总数量
for (i = 0; i < ngroups; i++)
     for (i = ac_2order; i < max_order; i++)
          // 遍历 i 对应 order list
          spin_lock(order list);
               if (ext4_mb_good_group(bb_group)))
                    break;
          spin_unlock(order list);

     ext4_mb_load_buddy(grp); // 可能睡眠

     if (!ext4_try_lock_group(group) || !ext4_mb_good_group(grp))
          ext4_unlock_group(group);
          continue;
     // 扫描空闲块
     ext4_mb_scan_group(grp)
     ext4_unlock_group(group);
```

问题：

链表无序遍历导致弹跳；可能先从目标组之前的组中分配块，存在潜在的分配-释放、释放-释放竞争。

mb_optimize_scan

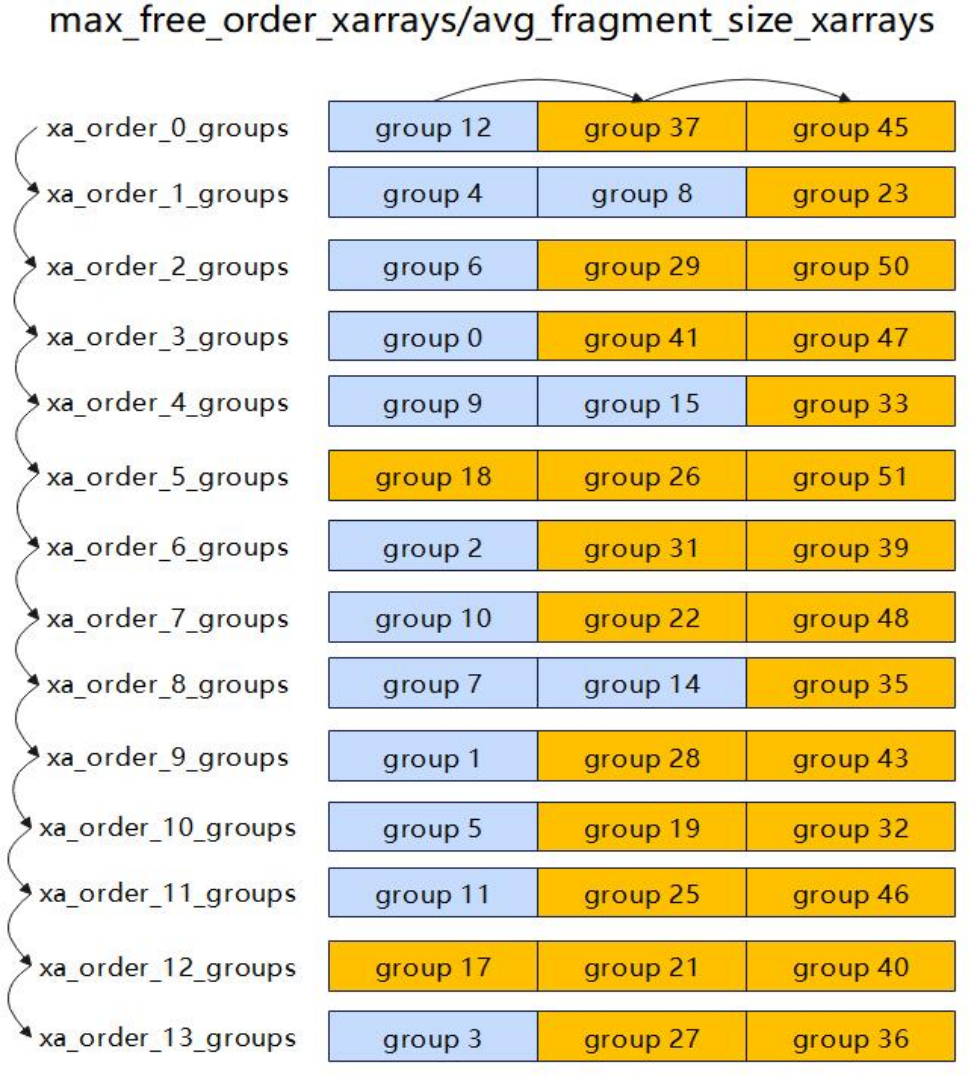

优化：

- 将无序的 list head 转换为有序的 xarry，group number 做为 xarray 的索引。有序队列即使遍历时放锁，也可以知道下一个 group，因而不会重复获取相同 group导致弹跳.
- 单向遍历：先遍历大于 goal group 的块组再遍历小于 goal group的块组。比如 goal group 是 16，先遍历所有list中黄色组再遍历所有list中蓝色组。这和线性遍历保持一致，可以减少竞争，并且对于 HDD 很友好。

优化效果

Test: Running will-it-scale/fallocate2 on CPU-bound containers.
Observation: Average fallocate operations per container per second.

CPU: Kunpeng 920	P80		P1	
Memory: 512GB				
960GB SSD (0.5GB/s)	base	patched	base	patched
mb_optimize_scan=0	2667	20049 (+651%)	314065	316724 (+0.8%)
mb_optimize_scan=1	2643	19342 (+631%)	316344	328324 (+3.7%)

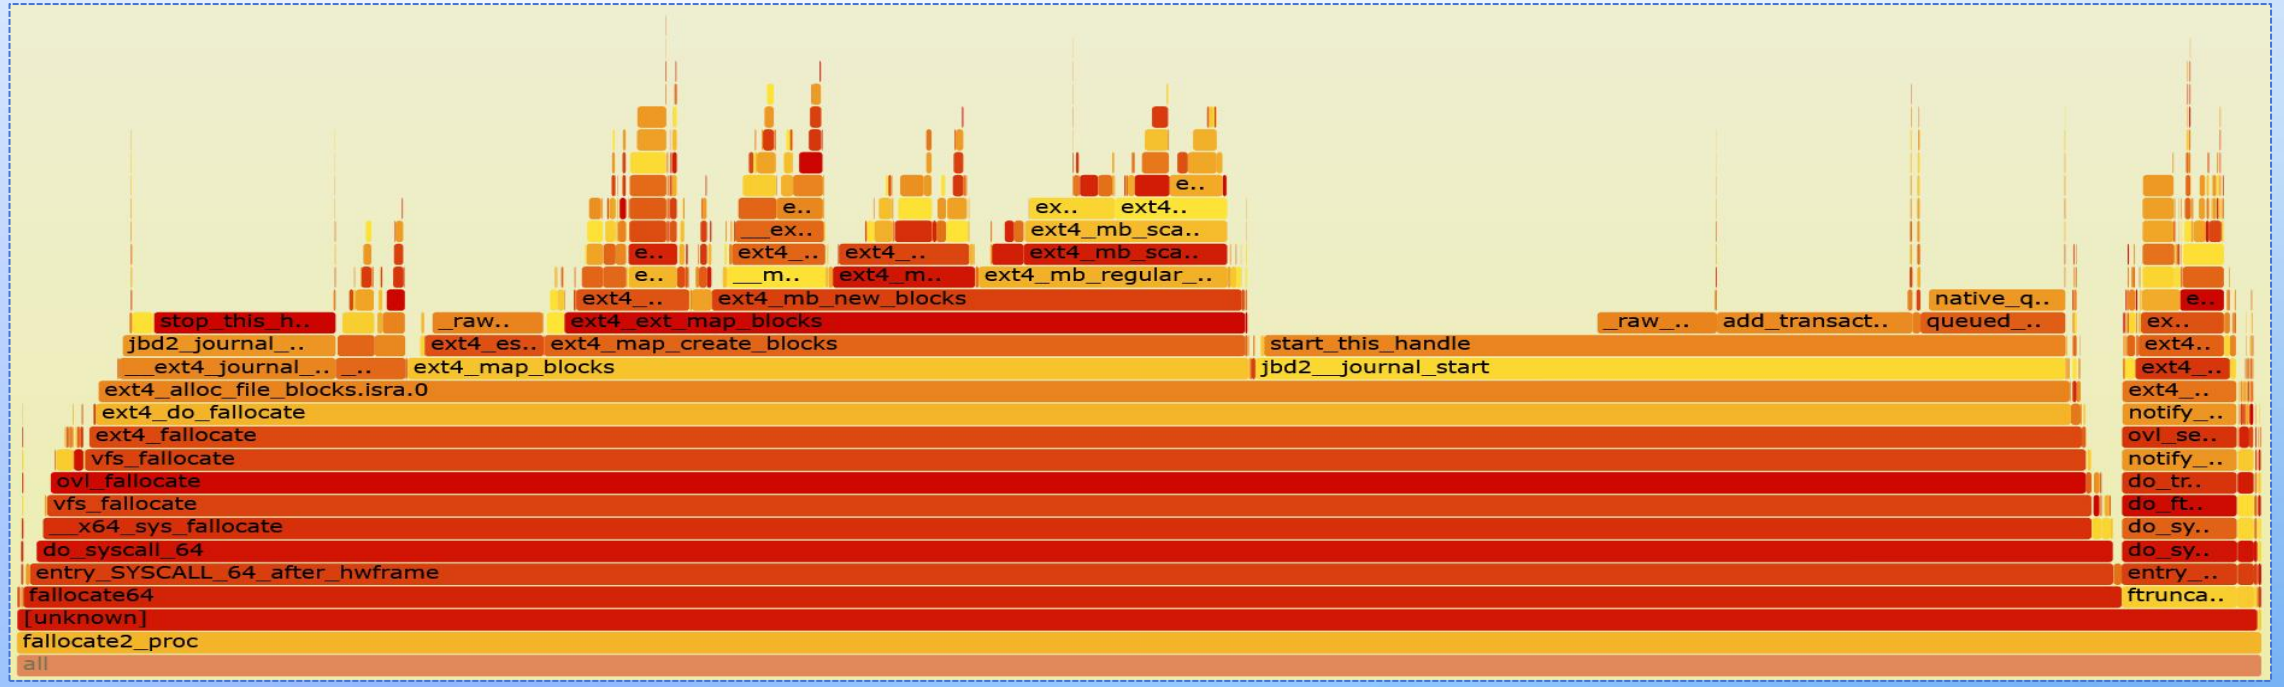

碎片化影响评估

测试 200G EXT4 文件系统 fio 64 进程 4k 追加 fallocate 到 1G，补丁对于碎片化的影响：

mb_optimize_scan	0		1	
	base	patched	base	patched
bw(MiB/s)	217	5718	217	5626
Avg. free extent size(KB)	1943732	1316212	1943732	1171208
Num. free extent	71	105	71	118
Avg. extents per file	261967	588	261973	570
Avg. size per extent(KB)	4	1780	4	1837
Fragmentation score	100	2	100	2

社区状态

- 社区状态：特性已合入Linux kernel v6.17
  - https://lore.kernel.org/linux-ext4/20250729033748.GA367490@mit.edu/
- 补丁集链接：
  - https://lore.kernel.org/linux-ext4/20250714130327.1830534-1-libaokun1@huawei.com/T/
- 社区News：
  - EXT4 Shows Wild Gains With Better Block Allocation Scalability In Linux 6.17
  - Linux 6.17 With EXT4 Showing Some Nice Performance Improvements

THANKS